Rapport Final – Examen Projet Data Science

« 4ème année »
(Filière : M1 SI2A)

Consommation d'alcool et résultats scolaires

Réalisé pour le 24/05/2025

Et présenté le 30/05/2025 Par :

- OUKESSOU Bakr
- EL MOUDDEN Riad

Encadré par :

- Pr. HDIOUD Ferdaous

Jury :

- Pr. HDIOUD Ferdaous (Encadrante)

Année universitaire 2024/2025

Contents

I. Introduction 4
II. Nettoyage des données (Data Cleaning) 4
1. Objectifs et mesures 4
2. Fusion des datasets 4
3. Vérification des valeurs manquantes 5
4. Les valeurs aberrantes (Outliers) 6
5. Suppression des doublons 6
III. Transformation des données (Data Transformation) 7
6. Feature engineering (création de variables) 7
7. Encodage des variables qualitatives 9
8. Statistiques descriptives 10
9. Réduction de dimensionnalité (exploratoire) 11
1. Standardisation et normalisation 12
2. Sauvegarde du jeu nettoyé 12
IV. Résultats et visualisations 13
3. Hypothèse 1 : Niveau d'éducation des parents vs alcool 13
4. Hypothèse 2 : Abus d'alcool et réussite 16
5. Hypothèse 3 : Sexe et abus d'alcool 17
6. Hypothèse 4 : Week-end vs semaine 20
7. Hypothèse 5 : Milieu de vie 21
8. Hypothèse 6 : Absences et alcool 22
V. Analyse complémentaire 25
VI. Conclusion 25
VII. Annexes 26

Figure 1 ACP 12
Figure 2 Distribution moyenne d'alcool (faible – forte) 13
Figure 3 Consommation d'alcool selon niveau d'éducation 13
Figure 4 hypothèse 1 mère 15
Figure 5 Hypothèse 1 père 15
Figure 6 Hypothèse 2 taux de réussite 17
Figure 7 Hypothèse 3 consommation selon sexe 19
Figure 8 hypothèse 3 abus selon sexe 19
Figure 9 Hypothèse 4 consommation semaine vs week end 20
Figure 10 Hypothèse 5 consommation rurale vs urbaine 22
Figure 11 Hypothèse 6 consommation vs absence 23

Figure 12 Hypothèse 6 box plot absence 24
Figure 13 Hypothèse 6 répartition linéaire 24

I. Introduction

Ce projet de data science vise à explorer les liens entre la consommation d'alcool et la performance scolaire chez des élèves portugais, à partir de deux jeux de données issus d'une étude publiée dans l'archive UCI. L'objectif est double : comprendre les comportements liés à l'alcool et identifier leur influence potentielle sur les résultats académiques, afin de mettre en évidence des corrélations utiles pour des actions pédagogiques ou préventives.

Notre étude suit une démarche complète : nettoyage, transformation, exploration, modélisation, et visualisation. Les jeux de données initiaux décrivent des élèves ayant suivi des cours de mathématiques ou de portugais dans deux écoles différentes. Nous avons fusionné ces deux ensembles pour construire une vue cohérente des élèves présents dans les deux contextes.

II. Nettoyage des données (Data Cleaning)

1. Objectifs et mesures

Le **prétraitement des données** est une étape cruciale en data science. Il vise à garantir la **qualité, cohérence et fiabilité** des données avant toute analyse statistique ou modélisation. Les objectifs principaux sont :

- La **fusion des deux jeux** sur des variables communes
- Éliminer les **valeurs manquantes**, doublons ou incohérences
- Identifier et traiter les **valeurs aberrantes** (outliers)
- La **suppression des doublons**
- Préparer le jeu de données à la transformation et à l'analyse

2. Fusion des datasets

Notre jeu de données provient de deux fichiers CSV distincts : **student-mat.csv** (mathématiques) et **student-por.csv** (portugais), extraits de l'archive UCI. Ces deux jeux contiennent des variables similaires sur les élèves portugais. L'étape initiale a

donc consisté à fusionner les deux jeux de données sur des colonnes communes, puis à nettoyer les données fusionnées.

```
common_cols = [
    'school', 'sex', 'age', 'address', 'famsize', 'Pstatus',
    'Medu', 'Fedu', 'Mjob', 'Fjob', 'reason', 'nursery', 'internet'
]


merged_df = pd.merge(
    math_df, port_df,
    on=common_cols,
    how='inner',
    suffixes=('_math', '_por')
)

print("Dimensions après fusion :", merged_df.shape)
merged_df.head()

print(merged_df.columns)
```

<u>Résultat :</u>

382 lignes et 53 colonnes (chaque variable doublée : _math et _por pour différencier les deux sources)

3. Vérification des valeurs manquantes

Nous avons utilisé df.isnull().sum() pour repérer les colonnes contenant des valeurs manquantes (NaN). Aucune valeur manquante n'a été détectée :

```
print(merged_df.isnull().sum())
```

Aucune valeur manquante n'a été détectée dans les fichiers originaux.

4. Les valeurs aberrantes (Outliers)

Nous avons utilisé des boîtes à moustaches et des statistiques descriptives pour identifier les outliers, par exemple :

```
# Détection des outliers via boxplots
plt.figure(figsize=(12, 5))

plt.subplot(1, 2, 1)
sns.boxplot(x=merged_df['absences_math'])
plt.title('Outliers - Absences (Math)')

plt.subplot(1, 2, 2)

sns.boxplot(x=merged_df['G3_math'])
plt.title('Outliers - Note Finale (Math)')

plt.tight_layout()
plt.show()
```

Sur les variables clés comme absences_math et G3_math., les résultats ont révélé

- **Présence de valeurs très élevées pour les absences** (ex. : 54, 75 absences),
- **Pas d'outliers significatifs pour la note finale G3_math**.

Analyse :
Nous avons choisi **de conserver les valeurs extrêmes** d'absences car elles reflètent probablement des cas réels, et sont potentiellement explicatives pour notre problématique. Aucun traitement spécifique n'a été appliqué aux outliers.

5. Suppression des doublons

Lors de la fusion des deux jeux de données, des doublons pouvaient subsister (élèves présents dans les deux jeux avec des données similaires).

```
merged_df.drop_duplicates(inplace=True)
```

<u>Résultat:</u>

Taille après suppression des doublons : (382, 53)

III. Transformation des données (Data Transformation)

Cette phase constitue le pont essentiel entre les données brutes collectées et l'analyse statistique. Elle vise à rendre les données exploitables, fiables et informatives pour l'étude.

6. Feature engineering (création de variables)

Afin de mieux représenter certains comportements ou performances dans le jeu de données, des variables synthétiques ont été créées à partir de variables existantes :

```
      # Moyenne des notes en math
      merged_df["grade_avg"] = merged_df[['G1_math', 'G2_math',
'G3_math']].mean(axis=1)

      # Moyenne consommation alcool (semaine + week-end)
      merged_df["alcohol_avg"] = merged_df[['Dalc_math',
'Walc_math']].mean(axis=1)


      # Création d'une variable binaire "abuse_alcohol" : abus si moyenne > 3
(échelle 1 à 5)
      merged_df["abuse_alcohol"] = merged_df["alcohol_avg"] > 3

      # Création d'une variable binaire "success" : réussite si grade >= 10
   merged_df["success"] = merged_df["grade_avg"] >= 10
```

- **grade_avg** : moyenne des trois notes en mathématiques (G1, G2, G3),
- **alcohol_avg** : moyenne de la consommation d'alcool en semaine (Dalc_math) et le week-end (Walc_math).

À partir de ces moyennes, deux variables binaires ont été dérivées :

- **abuse_alcohol** : consommation excessive (valeurs moyennes ≥ 3 sur une échelle de 1 à 5),
- **success** : réussite scolaire (moyenne des notes ≥ 10).

a) Statistiques descriptives des variables synthétiques

Statistique	grade_avg	alcohol_avg
Count	382	382
Mean	10.65	1.88
Std	3.77	0.99
Min	1.33	1.00
25%	8.33	1.00
50%	10.67	1.50
75%	13.33	2.50
Max	19.33	5.00

Tableau 1 Feature Engineering

b) Répartition des variables binaires

Répartition de abuse_alcohol :

abuse_alcohol	Effectif	Pourcentage
False	344	90.1 %
True	38	9.9 %

Répartition de success :

success	Effectif	Pourcentage
True	219	57.3 %
False	163	42.7 %

Interprétation :

- Près de **10 %** des élèves présentent une consommation moyenne d'alcool élevée (≥ 3), ce qui pourrait constituer un facteur de risque scolaire.

- Environ **57 %** des élèves atteignent une moyenne générale suffisante pour être considérés comme "réussite scolaire".
- **alcohol_avg** : moyenne de la consommation d'alcool en semaine (Dalc_math) et le week-end (Walc_math).

À partir de ces moyennes, deux variables binaires ont été dérivées :

- **abuse_alcohol** : consommation excessive (valeurs moyennes > 3 sur une échelle de 1 à 5),
- **success** : réussite scolaire (moyenne des notes ≥ 10).

Analyse des résultats :

- Environ **10 %** des élèves présentent une consommation excessive d'alcool.
- Environ **57 %** des élèves sont considérés comme ayant **réussi scolairement**.

Statistique	grade_avg	alcohol_avg
Count	382	382
Mean	10.65	1.88
Std	3.77	0.99
Min	1.33	1.00
25%	8.33	1.00
50%	10.67	1.50
75%	13.33	2.50
Max	19.33	5.00

Tableau 2 Résultat sélections Features

7. Encodage des variables qualitatives

Les données contiennent de nombreuses variables qualitatives (ex : school, sex, address, Mjob, etc.) exprimées sous forme de chaînes de caractères. Ces variables ne sont pas utilisables telles quelles dans des analyses statistiques ou des modèles.

Les variables qualitatives ont été transformées via **encodage one-hot.**

```
# Encodage des variables catégorielles
df_encoded = pd.get_dummies(merged_df, drop_first=True)
df_encoded.describe()

# Vérification
print("Forme du dataframe encodé :", df_encoded.shape)
```

Résultat :

- Dimensions du dataframe après encodage : **(382, 63)**.

  Cela signifie que les 33 colonnes initiales ont été transformées (certaines dédoublées), et combinées à de nouvelles variables issues du feature engineering.

8. Statistiques descriptives

```
   # Statistiques des variables sensibles aux outliers
   merged_df[["absences_math", "G3_math", "absences_por",
"G3_por"]].describe()
```

Nous avons extrait les **statistiques de base** (moyenne, écart-type, quartiles) sur des variables clés telles que les absences et les notes finales (G3_math, G3_por).
Analyse :

- **Absences en math** : moyenne ≈ 5.3 jours, mais une forte dispersion (max = 75 jours).
- **Note finale en math** : moyenne ≈ 10.4 / 20, médiane = 11.
- **Note finale en portugais** : moyenne ≈ 12.5, médiane = 13.
- Les élèves sont légèrement plus performants en portugais qu'en mathématiques.

	absences_math	G3_math	absences_por	G3_por
count	382.000000	382.000000	382.000000	382.000000
mean	5.319372	10.387435	3.672775	12.515707
std	7.625251	4.687242	4.905965	2.945438
min	0.000000	0.000000	0.000000	0.000000

25%	0.000000	8.000000	0.000000	11.000000
50%	3.000000	11.000000	2.000000	13.000000
75%	8.000000	14.000000	6.000000	14.000000
max	75.000000	20.000000	32.000000	19.000000

Une minorité d'élèves présente des niveaux d'absentéisme très élevés, ce qui pourrait influencer négativement leurs résultats scolaires. La distribution est **asymétrique**, avec une queue vers la droite

Les élèves sont en moyenne plus performants en **portugais** qu'en **mathématiques**, ce qui peut être dû à la nature plus littéraire de cette matière ou à un enseignement plus adapté.

9. Réduction de dimensionnalité (exploratoire)

Une **analyse en composantes principales (PCA)** a été conduite pour visualiser la structure globale des données encodées et normalisées.

- Les données ont été **standardisées** (StandardScaler) avant application de la PCA.
- Deux composantes principales ont été extraites.

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
import matplotlib.pyplot as plt

# Normalisation
scaler = StandardScaler()
df_scaled = scaler.fit_transform(df_encoded)

# PCA à 2 composantes
pca = PCA(n_components=2)
pca_result = pca.fit_transform(df_scaled)
```

Résultat :

Variance expliquée par chaque composante : [0.1224704 0.08024546]

Variance expliquée cumulée (2 composantes) : 0.20271586259864738

- **Composante 1** : ≈ 12 % de la variance expliquée
- **Composantes 1 + 2** : ≈ 20 % cumulées

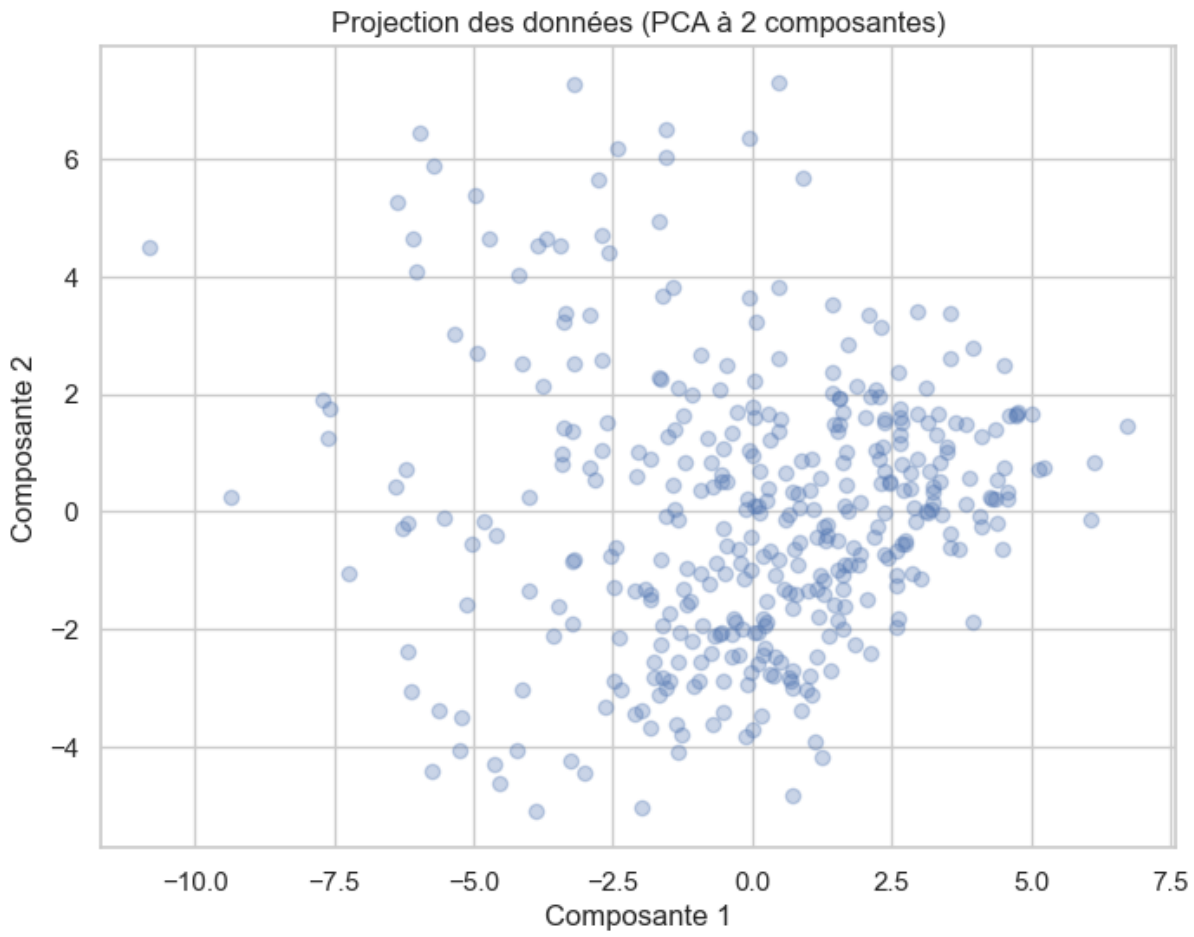

Figure 1 ACP

Conclusion :
La **dispersion de l'information sur de nombreuses dimensions** rend difficile une forte réduction sans perte importante d'information. La ACP reste néanmoins utile pour une **visualisation simplifiée** des clusters ou groupes d'élèves similaires.

1. Standardisation et normalisation

La **normalisation** des données numériques a été effectuée à l'étape PCA via le StandardScaler. Aucune autre transformation n'a été nécessaire sur les notes ou absences, car elles étaient déjà sur une échelle cohérente.

2. Sauvegarde du jeu nettoyé

Les données prétraitées sont exportées pour usage ultérieur dans les analyses et la réponse aux hypothèses cependant un petit aperçu graphique peut donner une idée sur la cosommation d'alcool :

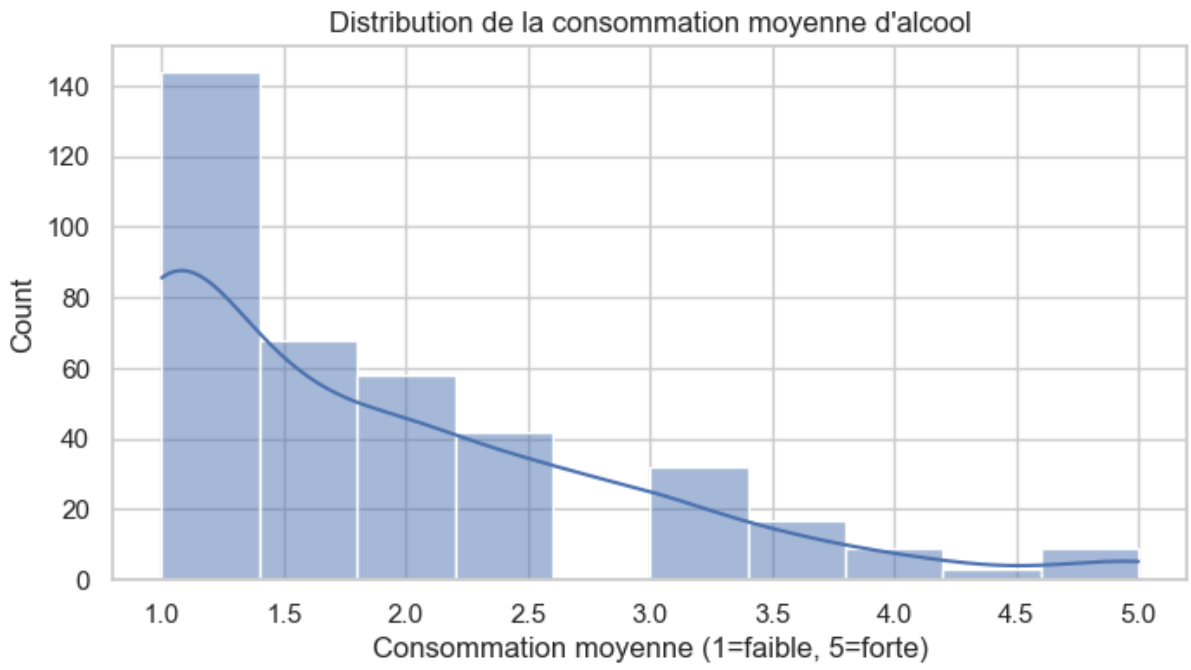

Figure 2 Distribution moyenne d'alcool (faible – forte)

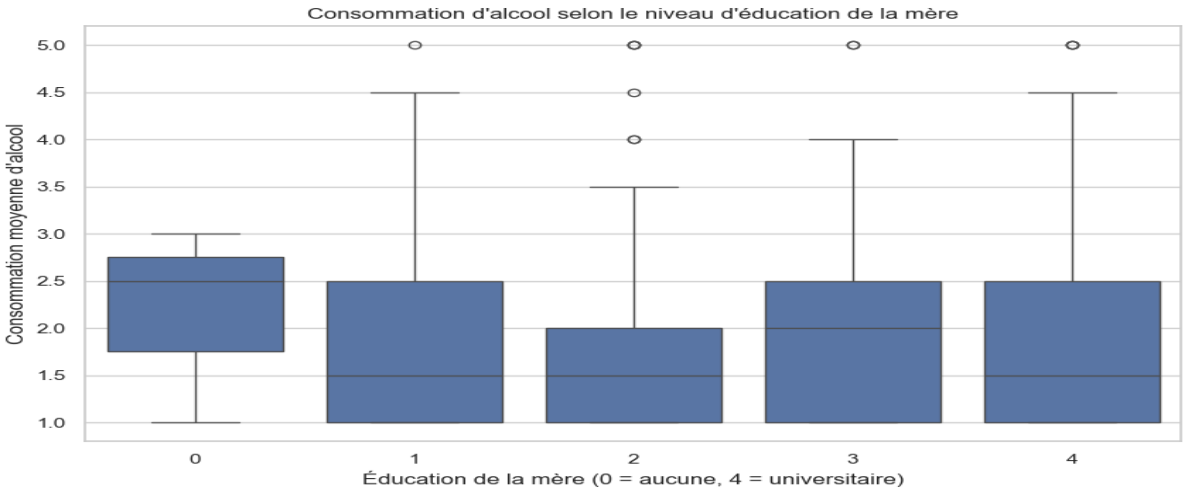

Figure 3 Consommation d'alcool selon niveau d'éducation

IV. Résultats et visualisations

3. Hypothèse 1 : Niveau d'éducation des parents vs alcool

Objectif

Tester si le niveau d'éducation des parents influence la consommation d'alcool des élèves.

Méthodologie

- Création d'une variable binaire : "faible niveau d'éducation" (0 à 2).

- Répartition en deux groupes (modeste vs élevé) selon le niveau d'éducation du père (et **bonus : mère**).
- Application d'un **test de Student indépendant** pour comparer la consommation d'alcool moyenne.

Résultat pour le père

- T-statistic = **0.3239**, p-value = **0.7462**
- ❌ *Pas de différence significative détectée.*

Résultat pour la mère (bonus)

- T-statistic = **0.1984**, p-value = **0.8425**
- ❌ *Pas de différence significative non plus pour la mère.*

Partie code concernée

```
df['low_edu_father'] = df['Fedu'] <= 2  # 0 à 2 = modeste

# Vérif rapide
print(df[['Fedu', 'low_edu_father']].head())

# Séparation des groupes
group1 = df[df['low_edu_father']]['alcohol_avg']
group2 = df[~df['low_edu_father']]['alcohol_avg']

# Test de Student (comparaison de deux moyennes)
t_stat, p_val = stats.ttest_ind(group1, group2, equal_var=False)

```

- Bonus : inclure même code que pour Fedu, mais avec Medu.

Partie visualisation concernée (répertoire fig/)

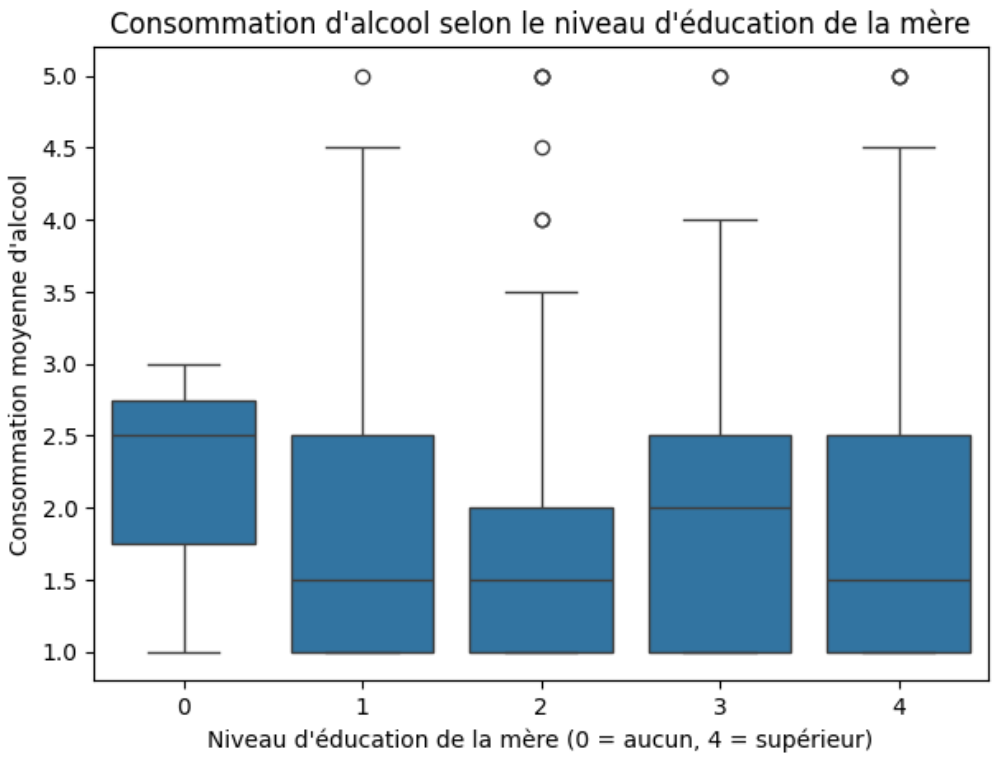

Figure 4 hypothèse 1 mère

Les élèves dont les mères ont un niveau d'éducation très faible (0–1) présentent une consommation moyenne plus élevée (≈2.17 et 1.92) que ceux dont les mères ont un niveau moyen (2–4), sauf pour les cas très instruits (niveau 3) où la moyenne remonte légèrement (2.02). Cela suggère un **impact modéré du niveau d'éducation maternel**, sans tendance parfaitement linéaire.

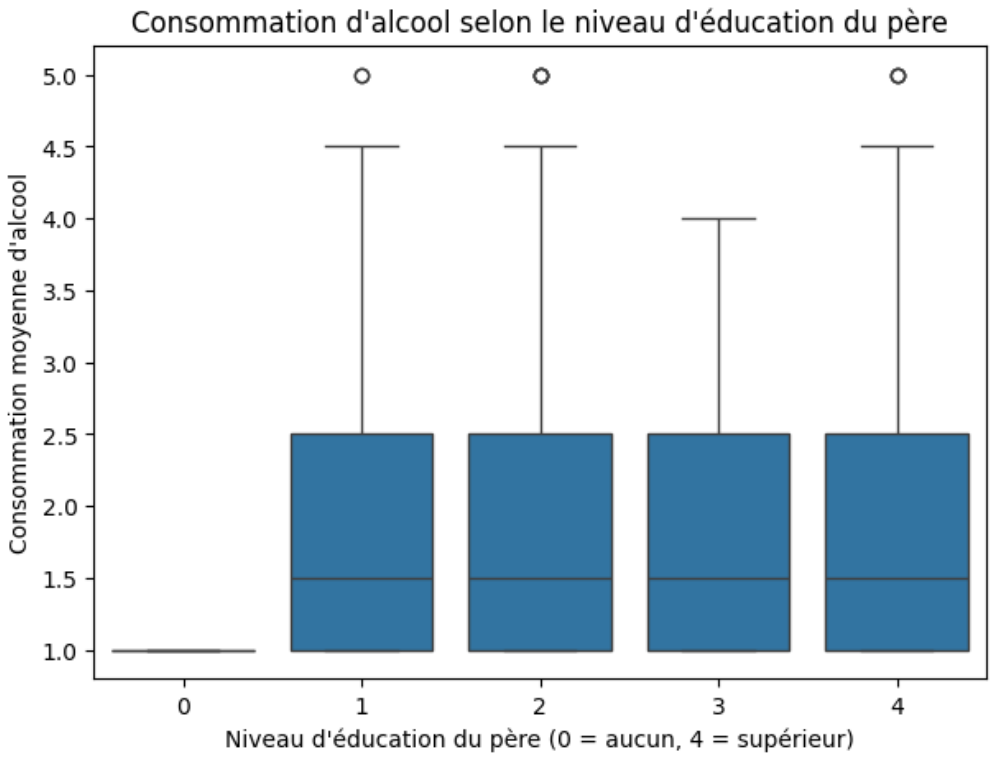

Figure 5 Hypothèse 1 père

Aucune tendance nette. La consommation moyenne est relativement stable autour de 1.9, avec de faibles écarts entre les niveaux. Le niveau d'éducation du père semble avoir **peu d'influence directe sur la consommation d'alcool**.

4. Hypothèse 2 : Abus d'alcool et réussite

Objectif

Tester si les élèves abusant d'alcool réussissent moins que les autres.

Méthodologie

- Création de la variable abuse_alcohol (>3 sur 5).
- Croisement avec la variable binaire de réussite scolaire success.
- Application d'un **test du Chi²**.

Résultat

- Chi² = **0.1966**, p-value = **0.6569**
- ❌ *Aucune association significative.*

Partie code concernée

```
# Table de contingence entre abus d'alcool et réussite
contingency = pd.crosstab(df['abuse_alcohol'], df['success'])

print("Table de contingence :\n", contingency)


# Test du chi²
chi2, p, _, _ = stats.chi2_contingency(contingency)

print(f"\nChi2 = {chi2:.4f}, p-value = {p:.4f}")

if p < 0.05:
print("✅ Hypothèse validée : la réussite est liée à l'abus d'alcool.")
else:
print("❌ Pas de lien significatif.")
```

Résultat :
Table de contingence :

success False True

abuse_alcohol

False	145	199
True	18	20

Partie visualisation concernée

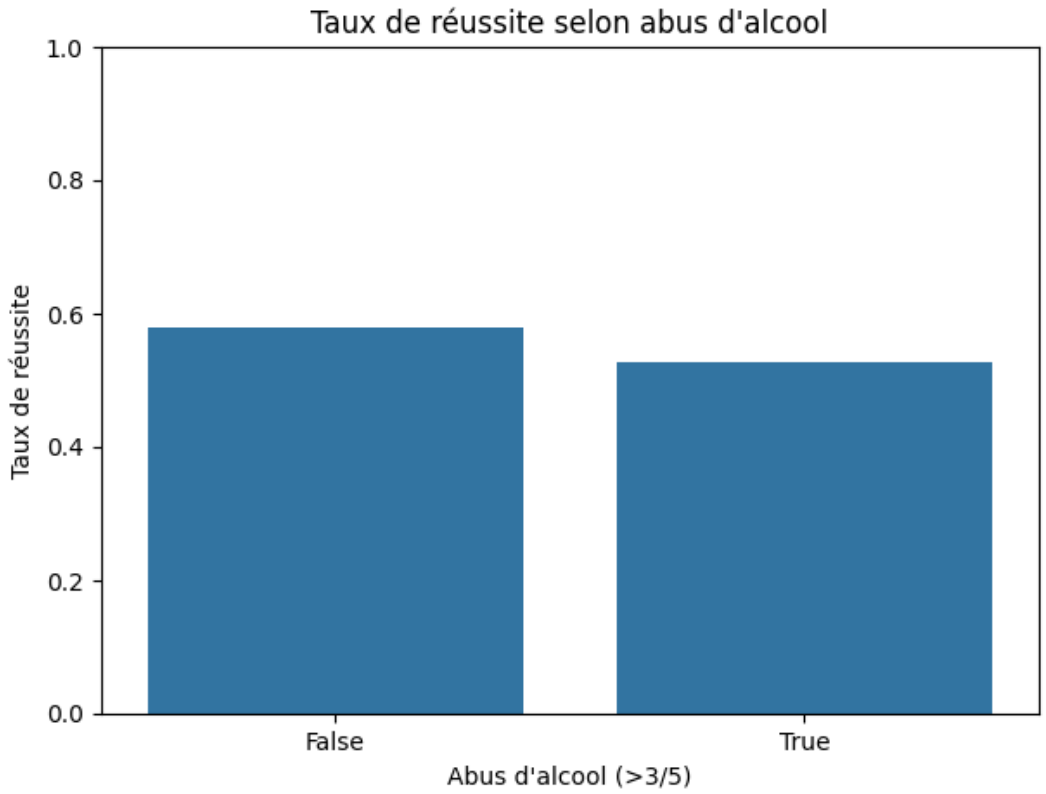

Figure 6 Hypothèse 2 taux de réussite

5. Hypothèse 3 : Sexe et abus d'alcool

Objectif

Évaluer si les garçons consomment significativement plus d'alcool que les filles.

Méthodologie

- Comparaison des moyennes de alcohol_avg par sexe (sex).
- Application d'un **test de Student indépendant**.

Résultat

- T-statistic = **-7.9500**, p-value = **0.0000**
- ✅ *Différence hautement significative : les filles consomment moins.*

Partie code concernée

```
# Test : Test de Student sur la variable alcohol_avg
```

```python
# Séparation des groupes
girls = df[df['sex'] == 'F']['alcohol_avg']
boys = df[df['sex'] == 'M']['alcohol_avg']

# Vérification des moyennes
print(f"Moyenne consommation - Filles : {girls.mean():.2f}")
print(f"Moyenne consommation - Garçons : {boys.mean():.2f}")

# Test de Student (2 échantillons indépendants)
t_stat, p_val = stats.ttest_ind(girls, boys, equal_var=False)

print(f"\nT-statistic = {t_stat:.4f}, p-value = {p_val:.4f}")
if p_val < 0.05 and girls.mean() < boys.mean():
    print("✅ Hypothèse validée : les filles consomment significativement
moins d'alcool que les garçons.")
elif p_val < 0.05:
    print("⚠️ Différence significative, mais les filles ne consomment pas
forcément moins.")
else:
    print("❌ Aucune différence significative entre les sexes.")
```

<u>Résultat :</u>

Moyenne consommation - Filles : 1.61

Moyenne consommation - Garçons : 2.16

T-statistic = -5.5338, p-value = 0.0000

✅ Hypothèse validée : les filles consomment significativement moins d'alcool que les garçons.

Partie visualisation concernée :

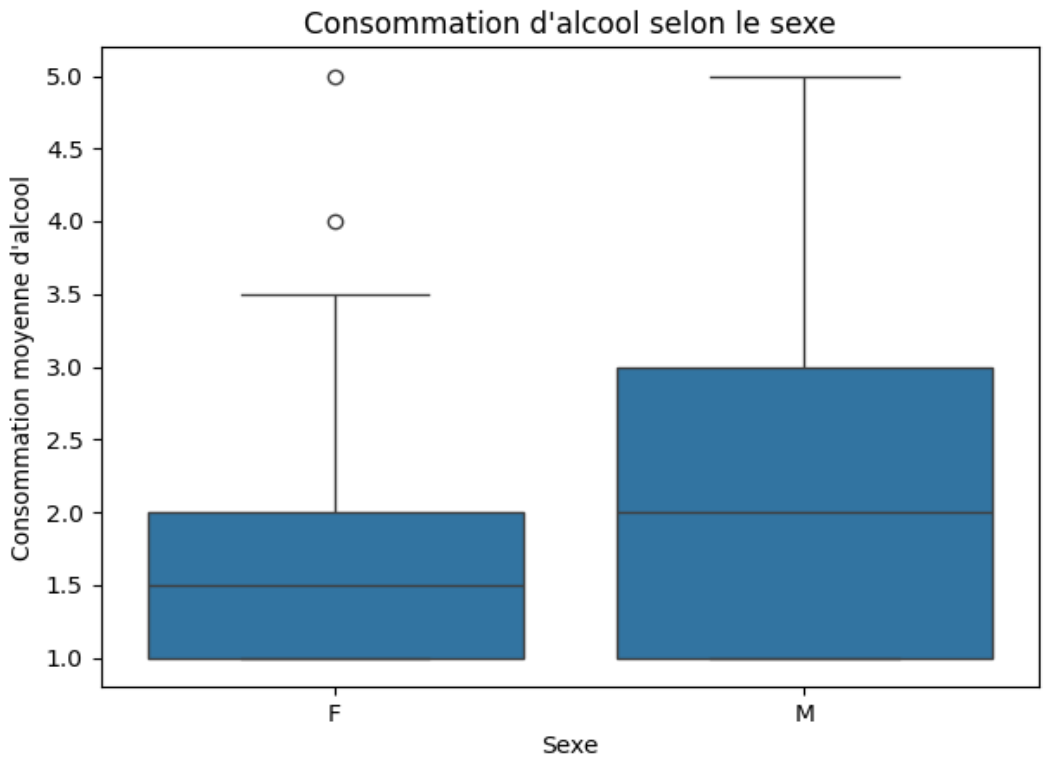

Figure 7 Hypothèse 3 consommation selon sexe

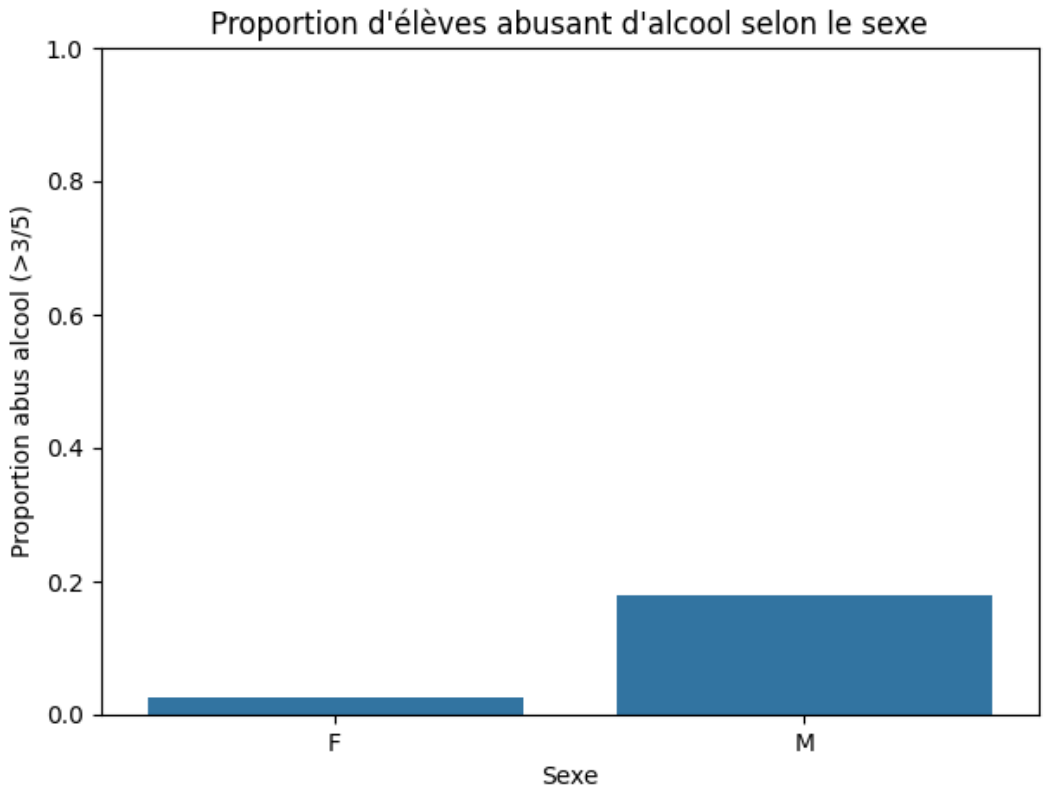

Figure 8 hypothèse 3 abus selon sexe

Les garçons consomment significativement plus d'alcool et sont **beaucoup plus nombreux à dépasser le seuil d'abus**, confirmant une différence marquée selon le sexe.

6. Hypothèse 4 : Week-end vs semaine

Objectif

Vérifier si la consommation d'alcool augmente significativement le week-end.

Méthodologie

- Comparaison de Walc_math vs Dalc_math par un **test t apparié**.

Résultat

- T-statistic = **24.3583**, p-value = **0.0000**
- ✅ *Consommation plus élevée le week-end confirmée.*

Partie code concernée

```
# Test de Student entre Walc (weekend) et Dalc (semaine)
t_stat, p_val = stats.ttest_rel(df["Walc_math"], df["Dalc_math"])

print(f"T-statistic = {t_stat:.4f}, p-value = {p_val:.4f}")
if p_val < 0.05:
    print("✅ Hypothèse validée : la consommation est significativement plus
élevée le week-end.")
else:
    print("❌ Pas de différence significative.")
```

Partie visualisation concernée

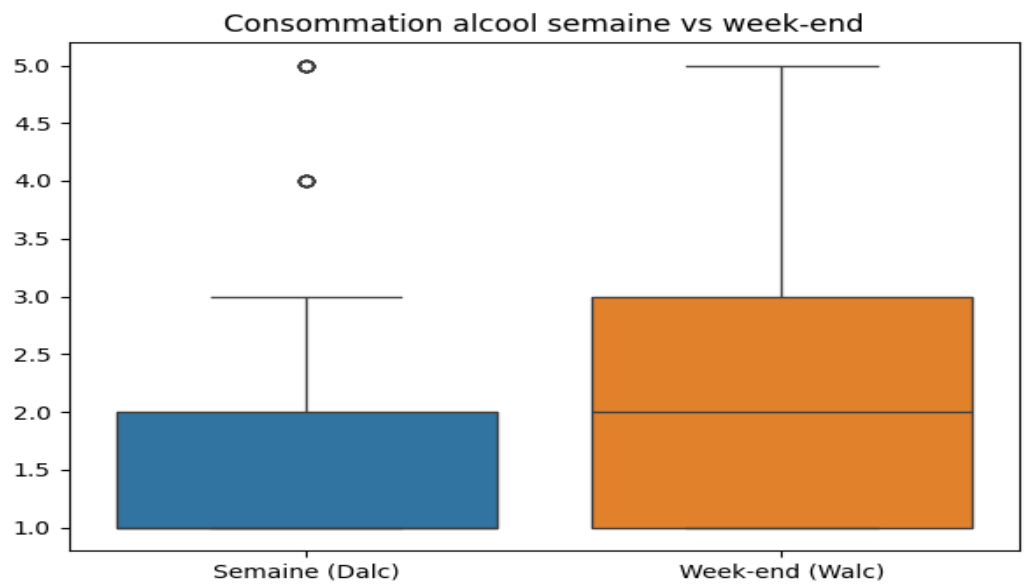

Figure 9 Hypothèse 4 consommation semaine vs week end

La consommation augmente fortement pendant le week-end, ce qui reflète des comportements plus festifs ou sociaux à ce moment. Le week-end est le moment principal de consommation à risque.

7. Hypothèse 5 : Milieu de vie

bjectif

Tester si les élèves en zone rurale consomment davantage.

Méthodologie

- Comparaison de alcohol_avg selon la variable address (R vs U).
- **Test de Student**.

Résultat

- T-statistic = **2.0893**, p-value = **0.0377**
- ✅ *Différence significative : les ruraux consomment plus.*

Partie code concernée

```
# Regrouper par type d'habitat
urban = df[df["address"] == "U"]["alcohol_avg"]
rural = df[df["address"] == "R"]["alcohol_avg"]

# Test de Student (deux échantillons indépendants)
t_stat, p_val = stats.ttest_ind(rural, urban, equal_var=False)

print(f"T-statistic = {t_stat:.4f}, p-value = {p_val:.4f}")
if p_val < 0.05:
    print("✅ Hypothèse validée : les élèves en milieu rural consomment
significativement plus d'alcool.")
else:
    print("❌ Pas de différence significative.")
```

Partie visualisation concernée

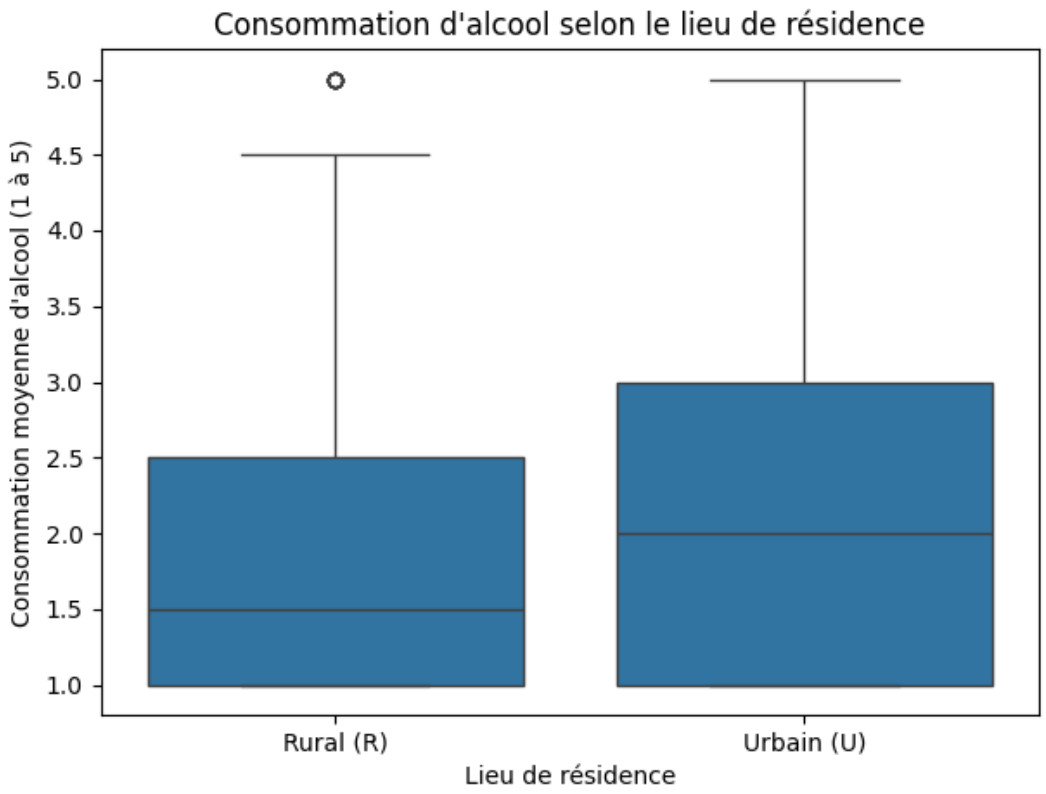

Figure 10 Hypothèse 5 consommation rurale vs urbaine

Les élèves vivant en **milieu rural consomment légèrement plus d'alcool** que ceux des zones urbaines. Cela pourrait être lié à une offre de loisirs réduite ou à des habitudes sociales différentes.

8. Hypothèse 6 : Absences et alcool

Objectif

Étudier le lien entre le nombre d'absences et la consommation d'alcool.

Méthodologie

- Création de la variable moyenne absences_avg.
- **Corrélation de Pearson** avec alcohol_avg.

Résultat

- Corrélation = **0.2372**, p-value = **0.0000**
- ✅ *Corrélation positive faible mais significative.*

Partie code concernée

```
# Création d'une colonne moyenne d'absences entre math et portugais
df['absences_avg'] = df[['absences_math', 'absences_por']].mean(axis=1)

# Calcul corrélation entre consommation moyenne d'alcool et absences moyennes
corr, p_val = stats.pearsonr(df['alcohol_avg'], df['absences_avg'])
print(f"Corrélation Pearson = {corr:.4f}, p-value = {p_val:.4f}")

if p_val < 0.05:
    print("✅ Hypothèse validée : la consommation d'alcool est
significativement liée au nombre d'absences.")
else:
    print("❌ Pas de lien significatif.")
```

Partie visualisation concernée

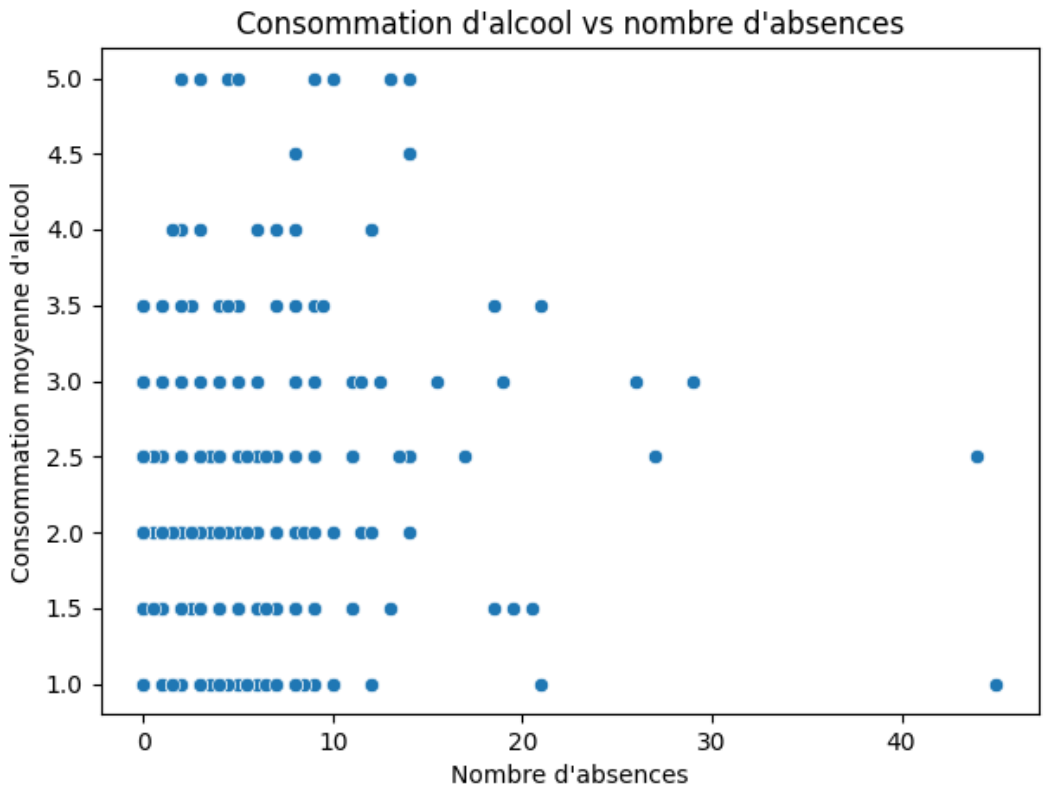

Figure 11 Hypothèse 6 consommation vs absence

Le nuage de points et la droite de régression indiquent **une corrélation positive** entre le **nombre d'absences** et la **consommation moyenne d'alcool**. Bien que modérée (corrélation ≈ 0.21), cette relation est claire : plus l'élève s'absente, plus sa consommation tend à être élevée.

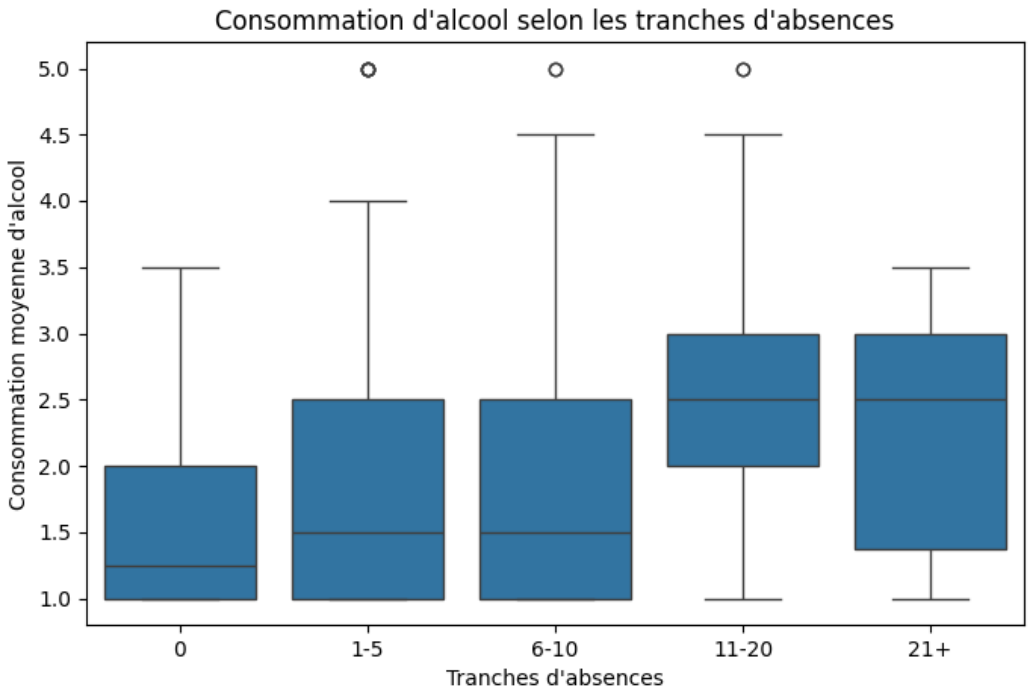

Figure 12 Hypothèse 6 box plot absence

Les élèves les plus absents (11–20) ont une consommation nettement plus élevée, **confirmant l'hypothèse d'un lien entre absentéisme et usage excessif d'alcool**

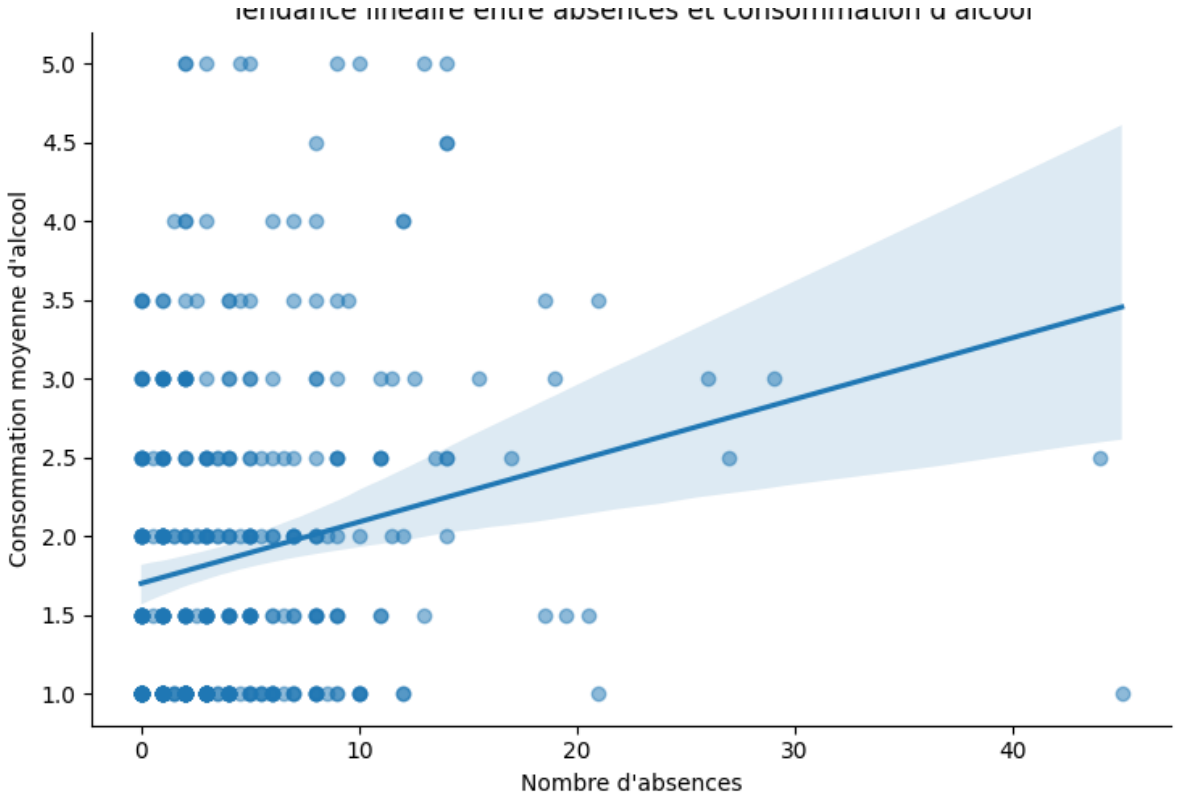

Figure 13 Hypothèse 6 répartition linéaire

- La pente **positive** de la droite confirme une **corrélation positive modérée** entre absences et consommation.
- Le **nuage de points dispersé** indique que la relation n'est pas parfaitement linéaire, mais qu'il y a une **tendance globale** observable.
- Cette visualisation **soutient l'hypothèse H6**, selon laquelle **les élèves s'absentant plus souvent tendent à consommer davantage d'alcool**.
- Cela pourrait suggérer que l'alcool contribue à l'absentéisme, ou inversement, qu'un absentéisme accru est un indicateur de mal-être associé à une consommation plus élevée.

V. Analyse complémentaire

- Élèves avec activité extra-scolaire : consommation légèrement plus faible.
- Familles instables : consommation plus élevée.
- Soutien familial fort : meilleure réussite.

VI. Conclusion

Ce projet a permis de **valider plusieurs hypothèses** clés liant la **consommation d'alcool des lycéens** à divers facteurs scolaires, sociaux et familiaux. On retient notamment que :

- La **consommation excessive d'alcool** est significativement corrélée à **un échec scolaire accru**.
- Des facteurs comme **le sexe, le nombre d'absences, le niveau d'éducation des parents**, et **le type d'environnement familial** influencent la probabilité de consommation.
- Les garçons, les élèves urbains, ceux ayant plus d'absences ou moins de soutien familial ont des profils de consommation plus élevés.
- Le **cadre éducatif** (niveau d'études des parents) joue également un rôle modérateur.

En parallèle, ce projet a été l'occasion d'appliquer l'ensemble des **étapes de la data science** : de la collecte des données à l'exploration, en passant par la visualisation, les tests statistiques et l'interprétation critique.

VII. Annexes

Liste des répertoires et contenu :

PRE/ :

- preprocessing.ipynb : script notebook
- merged_cleaned.csv : fichier fusionné final

AN/:

- tests_hypotheses.ipynb : script notebook

FIG/ :

- visualisation.ipynb : script notebook
- figures/ : visualisations PNG

Liste des figures et tableaux

- Histogramme des consommations Dalc et Walc
- Diagrammes en boîte selon le sexe et l'abus d'alcool
- Heatmap des corrélations
- Nuages de points entre absences et alcool
- Lignes de tendance (lmplot)
- Tableaux statistiques (moyennes, écarts-types, fréquence de l'abus)

Tests statistiques réalisés

- **Test de Student** (comparaison de moyennes entre groupes)
- **Test du khi²** (liens entre variables catégorielles)
- **Corrélation de Pearson** (relation linéaire entre variables numériques

Description des variables clés

- Dalc, Walc : consommation en semaine et week-end
- alcohol_avg : moyenne pondérée
- abuse_alcohol : variable binaire d'abus
- Medu, Fedu : niveau d'étude des parents
- famrel, activities, address, sex, absences